

Laboratório 03 — Caracterização de Code Review no GitHub

Caracterizando a Atividade de Code Review no GitHub: Um Estudo Empírico

1 Introdução

1.1 Contextualização

Code review é uma prática central da engenharia de software moderna, pois ajuda a identificar defeitos, disseminar conhecimento e aumentar a qualidade das mudanças antes de sua integração. No ecossistema do GitHub, essa prática ocorre majoritariamente por meio de *pull requests* (PRs), que registram o código proposto, as discussões, os comentários e os reviews formais associados à mudança. Compreender quais fatores influenciam a aceitação de um PR e a intensidade do processo de revisão é relevante tanto para pesquisadores quanto para desenvolvedores e mantenedores de projetos open-source.

1.2 Problema

Este estudo busca identificar quais características observáveis dos pull requests influenciam dois desfechos importantes do processo de code review no GitHub: **(A)** se o PR termina em MERGED ou CLOSED; e **(B)** quantos reviews formais o PR recebe. A análise é feita sob a

perspectiva de fatores perceptíveis aos desenvolvedores, como tamanho da mudança, tempo de análise, qualidade contextual da descrição e volume de interações ao redor da revisão.

1.3 Questões de Pesquisa

O estudo é guiado pelas seguintes questões de pesquisa:

Dimensão A — Fatores associados ao merge

- **RQ01:** O tamanho do pull request (arquivos alterados, adições e deleções) influencia seu estado final (MERGED vs CLOSED)?
- **RQ02:** O tempo de análise do pull request está associado ao seu estado final (MERGED vs CLOSED)?
- **RQ03:** O tamanho da descrição do pull request influencia seu estado final (MERGED vs CLOSED)?
- **RQ04:** O nível de interação no pull request (participantes e comentários) influencia seu estado final (MERGED vs CLOSED)?

Dimensão B — Fatores associados ao número de reviews

- **RQ05:** O tamanho do pull request (arquivos alterados, adições e deleções) está correlacionado ao número de reviews recebidos?
- **RQ06:** O tempo de análise do pull request está correlacionado ao número de reviews recebidos?
- **RQ07:** O tamanho da descrição do pull request está correlacionado ao número de reviews recebidos?
- **RQ08:** O nível de interação no pull request (participantes e comentários) está correlacionado ao número de reviews recebidos?

1.4 Hipóteses Informais

Com base na literatura sobre colaboração em software e na experiência prática com revisão de código, foram formuladas as seguintes hipóteses informais:

Dimensão A — Fatores associados ao merge (MERGED vs CLOSED):

PRs integrados tendem a ser menores (H01), ter tempo de análise moderado — nem curto demais nem excessivamente longo (H02), possuir descrições mais completas (H03) e apresentar interações mais qualificadas (H04).

Dimensão B — Fatores associados ao número de reviews: PRs maiores (H05), com maior tempo em análise (H06), descrições mais detalhadas (H07) e maior atividade de comentários e participantes (H08) tendem a receber mais reviews.

1.5 Objetivos

Objetivo principal: Caracterizar empiricamente a atividade de code review em pull requests do GitHub, identificando fatores associados ao merge de mudanças e ao número de reviews recebidos.


Objetivos específicos:

1. Construir um dataset de PRs provenientes dos 200 repositórios mais populares do GitHub.
 2. Coletar, para cada PR, métricas de tamanho, tempo de análise, descrição e interação.
 3. Comparar os grupos MERGED e CLOSED com testes estatísticos apropriados.
 4. Medir correlações entre as métricas observadas e o número de reviews.
 5. Confrontar os resultados obtidos com as hipóteses informais do estudo.
-

2 Metodologia

Este trabalho caracteriza-se como um estudo empírico observacional com mineração de dados públicos do GitHub. O dataset é formado pelos **200 repositórios mais estrelados** que possuem **ao menos 100 pull requests** com estado final MERGED ou CLOSED. Após a seleção dos repositórios, são considerados apenas PRs com **pelo menos 1 review** e **duração mínima de 1 hora** entre criação e fechamento/merge.

A coleta ocorre em duas etapas: (1) descoberta dos repositórios elegíveis via **GitHub GraphQL API**; e (2) coleta paginada pull requests por repositório, também via GraphQL. A análise quantitativa utiliza o teste de **Mann-Whitney U** para a Dimensão A e a **correlação de Spearman** para a Dimensão B, sempre com $\alpha = 0,05$.



Fluxograma da Metodologia

2.1 Decisões Relevantes

ID	Decisão	Justificativa
D1	Limite de 200 PRs por repositório	Repositórios grandes possuem milhares de PRs; o limite mantém o dataset gerenciável e respeita rate-limits
D2	Descarte de repositórios sem PRs elegíveis	Dos 200 repositórios iniciais, 12 não produziram nenhum PR após a aplicação dos filtros (≥ 1 review, duração $\geq 1h$), resultando em 188 repositórios no dataset final


2.2 Métricas analisadas

Dimensão	Métricas
Tamanho	changed_files, additions, deletions
Tempo de análise	time_to_close_hours
Descrição	body_length
Interações	participants_count, comments_count
Variável dependente A	state (MERGED / CLOSED)
Variável dependente B	reviews_count

3 Resultados

3.1 Visão Geral do Dataset


O dataset final contém **12.955 pull requests** provenientes de **188 repositórios únicos** dentre os 200 inicialmente selecionados. Desse total, **10.053 PRs (77,6%)** terminaram em MERGED e **2.902 PRs (22,4%)** em CLOSED. Considerando toda a amostra, a mediana de `reviews_count` foi **2,0**.



Visão geral do dataset


3.2 Dimensão A — Resultados Consolidados

De forma agregada, a Dimensão A mostra diferenças estatisticamente detectáveis entre MERGED e CLOSED para tamanho, tempo de análise, tamanho da descrição e parte das interações. As distribuições visuais abaixo complementam os testes de Mann-Whitney U.




Violin plots da Dimensão A

Algumas métricas (e.g., linhas adicionadas, tempo de análise) possuem distribuições altamente assimétricas com outliers extremos que comprimem a visualização. A figura abaixo apresenta os mesmos dados com o eixo Y limitado ao intervalo interquartil ($IQR \times 1.5$), permitindo uma melhor comparação visual entre os grupos MERGED e CLOSED:



Violin plots da Dimensão A — sem outliers



Tamanhos de efeito da Dimensão A

RQ	Métrica	Mediana MERGED	Mediana CLOSED	U	p-valor	r
RQ01	changed_files	2.0	1.0	16995601.5	7.80×10^{-45}	-0.165
RQ01	additions	26.0	20.0	15286229.5	7.92×10^{-5}	-0.048
RQ01	deletions	5.0	2.0	17431931.5	1.82×10^{-58}	-0.195
RQ02	time_to_close_hours	24.26h	89.71h	10567373.0	1.45×10^{-113}	0.276
RQ03	body_length	665 caracteres	717 caracteres	14034456.0	1.85×10^{-3}	0.038
RQ04	participants_count	2.0	2.0	14641326.0	0.747	-0.004
RQ04	comments_count	1.0	2.0	12592963.0	1.75×10^{-30}	0.137

RQ01 — Tamanho do PR. Os três testes foram **estatisticamente significativos** ($p < 0,05$). Como o coeficiente rank-biserial foi **negativo**, o primeiro grupo (MERGED) tende a apresentar valores mais altos; neste dataset, PRs MERGED foram ligeiramente **maiores**, e não menores, do que PRs CLOSED.


RQ02 — Tempo de análise. time_to_close_hours apresentou o **maior efeito da dimensão** ($r = 0.276$). PRs CLOSED permaneceram muito mais tempo abertos do que PRs MERGED (**89,71h** vs **24,26h**), sugerindo estagnação ou impasse como sinal relevante de não integração.

RQ03 — Tamanho da descrição. Houve **significância estatística**, mas com **efeito negligível** ($r = 0.038$). Na prática, descrições ligeiramente maiores apareceram em CLOSED (**717** vs **665** caracteres), indicando que comprimento bruto não explica o merge.

RQ04 — Interações. Para `participants_count`, **não houve diferença estatisticamente significativa** ($p = 0,747$). Já `comments_count` foi maior em CLOSED, com **efeito fraco** ($r = 0.137$), sugerindo que mais comentários podem refletir fricção, retrabalho ou controvérsia.

As figuras individuais abaixo detalham cada RQ da Dimensão A:


RQ01 — Tamanho: Violin plots em escala logarítmica comparando `changed_files`, `additions` e `deletions` entre MERGED e CLOSED. As medianas anotadas mostram que PRs integrados apresentam valores ligeiramente superiores (med=2 vs 1 em arquivos, 26 vs 20 em adições, 5 vs 2 em deleções).



RQ01 — Tamanho vs Estado


RQ02 — Tempo de análise: Distribuição de `time_to_close_hours` por estado. A separação visual é evidente — PRs CLOSED possuem cauda muito mais longa, com mediana $\sim 4\times$ maior que MERGED.

RQ02 - Tempo de análise vs feedback final




RQ02 — Tempo vs Estado

RQ03 — Descrição: Comparação de body_length entre os grupos. As distribuições são muito semelhantes, consistente com o efeito negligível encontrado no teste estatístico.



RQ03 — Descrição vs Estado


RQ04 — Interações: Box plots de participants_count e comments_count. Para participantes, as distribuições são praticamente idênticas; para comentários, PRs CLOSED apresentam leve deslocamento para cima.



RQ04 — Interações vs Estado

3.3 Dimensão B — Resultados Consolidados

Na Dimensão B, avaliamos a correlação monotônica entre as métricas observadas e `reviews_count` por meio da correlação de Spearman. De forma geral, todas as correlações foram positivas, mas com magnitudes predominantemente fracas; a mediana global de `reviews_count` foi **2,0**.



Barras de correlação da Dimensão B

RQ	Métrica	Mediana	ρ (Spearman)	p-valor	Interpretação
RQ05	<code>changed_files</code>	2.0	0.254	4.56×10^{-190}	efeito fraco
RQ05	<code>additions</code>	24.0	0.317	3.25×10^{-301}	efeito moderado
RQ05	<code>deletions</code>	4.0	0.179	1.94×10^{-93}	efeito fraco
RQ06	<code>time_to_close_hours</code>	30.12h	0.098	3.36×10^{-29}	efeito negligível
RQ07	<code>body_length</code>	678 caracteres	0.200	2.05×10^{-116}	efeito fraco
RQ08	<code>participants_count</code>	2.0	0.363	≈ 0 (underflow)	efeito moderado
RQ08	<code>comments_count</code>	1.0	0.275	6.12×10^{-224}	efeito fraco

RQ05 — Tamanho do PR. Todas as correlações foram **estatisticamente significativas** ($p < 0,05$) e **positivas**. Isso sugere que PRs maiores tendem a receber mais reviews, com destaque para `additions`, única métrica com **efeito moderado** ($\rho = 0,317$).


RQ06 — Tempo de análise. Houve **significância estatística**, mas com **efeito negligível** ($\rho = 0,098$). Portanto, embora PRs que ficam mais tempo abertos tendam a acumular mais reviews, essa associação é muito fraca em termos práticos.

RQ07 — Tamanho da descrição. `body_length` apresentou correlação **positiva** e de **magnitude fraca** ($\rho = 0,200$). Assim, descrições mais longas tendem a estar associadas a mais reviews, embora o efeito esteja longe de ser dominante.

RQ08 — Interações. As duas correlações foram **estatisticamente significativas** ($p < 0,05$), e `participants_count` apresentou a **maior associação de toda a Dimensão B** ($\rho = 0,363$, efeito moderado). `comments_count` também mostrou associação positiva, mas com **efeito fraco** ($\rho = 0,275$).

As figuras individuais abaixo detalham cada RQ da Dimensão B, mostrando scatter plots com linha de tendência LOWESS:


RQ05 — Tamanho vs Reviews: PRs com mais linhas adicionadas tendem a receber mais revisões. A tendência é mais clara em additions ($\rho=0.317$) do que em deletions ($\rho=0.179$).



RQ05 — Tamanho vs Reviews

RQ06 — Tempo vs Reviews: A relação entre tempo aberto e número de reviews é quase plana, confirmando a correlação negligível ($\rho=0.098$).


RQ06 - Tempo de análise vs numero de revisoes



RQ06 — Tempo vs Reviews


RQ07 — Descrição vs Reviews: Descrições mais longas apresentam tendência positiva fraca com o número de reviews ($\rho=0.200$).

RQ07 - Descricao vs numero de revisoes




RQ07 — Descrição vs Reviews

RQ08 — Interações vs Reviews: A associação mais forte do estudo: mais participantes e comentários estão claramente ligados a mais reviews ($\rho=0.363$ e $\rho=0.275$, respectivamente).



RQ08 — Interações vs Reviews

A matriz abaixo resume todas as correlações de Spearman entre as variáveis numéricas do dataset, permitindo identificar visualmente quais métricas possuem associações mais fortes entre si:



Heatmap de correlações Spearman

4 Discussão

Os resultados mostram que a atividade de code review, no conjunto analisado, é influenciada por múltiplos fatores, mas com intensidades distintas. Na **Dimensão A**, o sinal mais claro para o estado final do PR

foi o **tempo de análise**; na **Dimensão B**, o número de reviews cresceu principalmente com **participantes**, **comentários** e, em menor grau, com o **tamanho do PR**.

4.1 Confronto com as hipóteses

- **H01** — ❌ **Refutada**: houve diferença estatística, mas PRs MERGED foram ligeiramente maiores em `changed_files`, `additions` e `deletions` (r entre -0.048 e -0.195).
- **H02** — ✅ **Confirmada**: `time_to_close_hours` diferenciou claramente os grupos (24,26h em MERGED vs 89,71h em CLOSED, $r = 0.276$).
- **H03** — ⚠️ **Parcial**: `body_length` teve efeito negligível ($r = 0.038$) e direção oposta à hipótese, com descrições um pouco maiores em CLOSED.
- **H04** — ⚠️ **Parcial**: `participants_count` não diferiu entre os grupos, e `comments_count` foi maior em CLOSED ($r = 0.137$).
- **H05** — ✅ **Confirmada**: todas as métricas de tamanho correlacionaram positivamente com `reviews_count` ($\rho = 0.179$ a 0.317).
- **H06** — ⚠️ **Parcial**: a correlação entre tempo de análise e `reviews_count` foi positiva, mas negligível ($\rho = 0.098$).
- **H07** — ✅ **Confirmada**: `body_length` apresentou correlação positiva e fraca com `reviews_count` ($\rho = 0.200$).
- **H08** — ✅ **Confirmada**: as métricas de interação tiveram as associações mais fortes com `reviews_count`, sobretudo `participants_count` ($\rho = 0.363$).

4.2 Principais achados e surpresas

O principal achado foi que o **tempo de análise** discrimina melhor o desfecho do PR do que métricas de tamanho ou descrição. Também surgiram resultados contraintuitivos: PRs MERGED foram ligeiramente maiores, e descrições mais longas ou mais comentários apareceram mais associados a CLOSED, sugerindo que volume de texto pode refletir complexidade, retrabalho ou controvérsia, e não necessariamente clareza ou colaboração produtiva.

5 Conclusão

Este estudo analisou **12.955 pull requests** de **188 repositórios** do GitHub para caracterizar fatores associados ao estado final dos PRs e ao número de reviews recebidos. O achado mais forte foi o **tempo de análise**: PRs CLOSED permaneceram abertos muito mais tempo do que PRs MERGED. Para o número de reviews, as associações mais relevantes vieram das métricas de **interação**, especialmente `participants_count`, seguidas por `comments_count` e por parte das métricas de tamanho. Também observamos que PRs MERGED foram ligeiramente maiores e que descrições mais longas não implicaram maior chance de merge. Na prática, equipes podem usar sinais de estagnação e de dinâmica social para priorizar revisões e identificar PRs com maior risco de não integração.

Referências

- GitHub. *GraphQL API Documentation*. Disponível em: <https://docs.github.com/en/graphql>.
- Spearman, C. (1904). *The proof and measurement of association between two things*.
- Mann, H. B.; Whitney, D. R. (1947). *On a test of whether one of two random variables is stochastically larger than the other*.